

Universidad Católica Boliviana "San Pablo"



Caso 7 — Medical Cost Prediction (Seguros)

Predicción de gastos médicos y recuperación de la condición de fumador mediante aprendizaje supervisado

Integrantes: Mauricio Orlando Rivera Mayan

Rodrigo Gabriel Rivera Mayan

Laura Yackelin Perez Estrada

Docente: Paton Gutierrez Ovidio Roger

1. Descripción del problema

Una aseguradora necesita estimar el gasto médico anual (charges) de sus asegurados para apoyar la fijación de primas, y además recuperar la condición de fumador (smoker) cuando este dato falta en el registro, ya que es uno de los factores de riesgo más relevantes del negocio. El caso plantea dos tareas de aprendizaje supervisado sobre el mismo conjunto de datos: (1) una tarea de regresión para predecir charges a partir de variables demográficas y de salud, y (2) una tarea de clasificación binaria para imputar smoker cuando no está disponible, usando únicamente variables que estarían presentes antes de conocer el gasto (age, sex, bmi, children, region).

El dataset utilizado es Medical Cost Personal Datasets (Kaggle), con 1338 registros y 7 columnas: age, sex, bmi, children, smoker, region y charges. Se identificó 1 fila duplicada, que se conserva sin alterar el pipeline de modelado (no afecta las métricas reportadas, dado su peso marginal sobre 1338 observaciones).

2. Preprocesamiento

Antes de cualquier ajuste se separó el 20% de los datos como conjunto de prueba (train_test_split, random_state=42), de modo que ninguna estadística del conjunto de prueba participa en el entrenamiento ni en la selección de hiperparámetros. Todo el preprocesamiento se encapsuló dentro de un Pipeline de scikit-learn junto con el modelo, para evitar fuga de información (data leakage) y garantizar que las mismas transformaciones se apliquen de forma idéntica en entrenamiento y en producción.

Se definió un transformador personalizado (CrearVariablesMedicas) que mapea sex (female→0, male→1) y smoker (no→0, yes→1), y construye la variable de interacción BMI_Smoker = bmi × smoker, que permite que el efecto del índice de masa corporal sobre el gasto sea distinto entre fumadores y no fumadores. Sobre las variables resultantes se aplicó un ColumnTransformer con tres ramas: variables numéricas (age, bmi, children, BMI_Smoker) imputadas por mediana y escaladas con StandardScaler; variables binarias (sex, smoker) imputadas por moda; y la variable categórica region, imputada por moda y codificada con OneHotEncoder.

Sobre calidad del dato: no se detectaron valores nulos en ninguna columna. La distribución de charges presenta asimetría positiva marcada (coeficiente de asimetría ≈ 1.52) y 139 observaciones por encima del límite superior de la regla IQR ($Q3 + 1.5 \cdot \text{RIC}$). Se decidió no eliminar estos valores extremos porque representan gastos médicos reales y de alto interés para el negocio (son precisamente los casos de mayor riesgo que la aseguradora necesita anticipar); su presencia sí explica parte de la brecha entre MAE y RMSE reportada en la sección 4.

3. Modelado

3.1 Regresión: predicción de charges

Se entrenaron y compararon dos modelos: (a) un baseline de regresión lineal simple sobre las variables preprocesadas, y (b) una alternativa con PolynomialFeatures(grado 2) seguida de Ridge, que captura relaciones no lineales e interacciones adicionales entre variables. El hiperparámetro de regularización alpha de Ridge se seleccionó únicamente con validación cruzada de 5 folds sobre el conjunto de entrenamiento (GridSearchCV, métrica neg_mean_absolute_error), sin tocar el conjunto de prueba.

El mejor valor encontrado fue alpha = 1.0, con un MAE promedio de validación cruzada de 2,968.40. Este valor de alpha se usó para reentrenar el modelo final y evaluarlo sobre el conjunto de prueba (sección 4).

3.2 Clasificación: imputación de smoker

Para simular el escenario de datos faltantes se ocultó, con semilla fija, el 20% de las etiquetas smoker (267 registros), conservando la verdad solo para fines de validación. Como decisión metodológica explícita contra la fuga de información, charges no se usó como predictor de smoker: en una aplicación real el gasto aún no estaría disponible en el momento de imputar la condición de fumador.

El modelo baseline fue una regresión logística (`class_weight='balanced'` para compensar el desbalance de clases, ya que solo ~20% de los asegurados son fumadores) sobre un pipeline con las mismas prácticas de imputación/escalado/codificación que en la regresión, mediante un `ColumnTransformer` independiente para las variables predictoras (age, sex, bmi, children, region).

4. Evaluación

4.1 Métricas de regresión (conjunto de prueba, 268 observaciones)

Modelo	MAE	RMSE	R ²
Regresión lineal	2,756.90	4,573.81	0.8653
Polinomios grado 2 + Ridge	2,689.80	4,591.33	0.8642

El modelo polinomial + Ridge logra el menor MAE (mejora de ~67 en promedio respecto al baseline lineal), pero un RMSE y R² prácticamente iguales — incluso marginalmente peores en RMSE. Esto indica que la ganancia del modelo más complejo es modesta y se concentra en reducir errores típicos, sin corregir de forma clara los errores grandes asociados a los gastos extremos; dado que la mejora es pequeña frente a la complejidad adicional, el modelo lineal sigue siendo una alternativa razonable si se prioriza interpretabilidad.




Figura 1. Valores reales vs. predichos (ambos modelos) y residuos del modelo Polinomios + Ridge.




Figura 2. Curva de aprendizaje (MAE) — Polinomios + Ridge. Entrenamiento y validación convergen, sin brecha amplia: más datos no aportarían una mejora sustancial adicional.

4.2 Métricas de clasificación (imputación de smoker, validación: 268 casos)

ROC-AUC en el conjunto de validación: 0.5267 (umbral 0.50). Este valor está apenas por encima de 0.50 (equivalente a una clasificación aleatoria), lo que señala que age, sex, bmi, children y region tienen poder predictivo muy limitado sobre smoker — una limitación relevante que se retoma en la sección 6.

Umbral	Accuracy	Precision	Recall	F1	FP	FN
0.30	0.201	0.201	1.000	0.335	214	0
0.40	0.269	0.204	0.907	0.333	191	5
0.50	0.567	0.228	0.481	0.310	88	28
0.60	0.791	0.400	0.074	0.125	6	50
0.70	0.799	0.000	0.000	0.000	0	54




Figura 3. Curva ROC y matriz de confusión (umbral 0.50) para la imputación de smoker.

4.3 Interpretación de coeficientes (modelo de regresión)

Los coeficientes se reportan como señales del modelo dentro de un espacio de características polinomiales, no como efectos causales: en un modelo con interacciones y términos cuadráticos, cada coeficiente combina el efecto de varias variables a la vez y depende de la escala estandarizada usada.




Figura 4. Términos con mayor magnitud de coeficiente — Polinomios + Ridge.

El término bmi×smoker (BMI_Smoker) y sus combinaciones con region concentran las magnitudes más altas, consistente con la evidencia exploratoria: el efecto del IMC sobre el gasto es mucho mayor en fumadores que en no fumadores, y ese efecto varía por región. age también aparece entre los términos más influyentes, en línea con el patrón esperado de mayor gasto médico a mayor edad.

5. Decisiones metodológicas y trade-offs

- Umbral de clasificación: no se fija un umbral operativo definitivo. La tabla 4.2 muestra que mover el umbral de 0.30 a 0.70 desplaza el balance entre falsos positivos y falsos negativos de un extremo a otro (de 214 FP / 0 FN a 0 FP / 54 FN), sin que ningún punto domine claramente en accuracy y F1 a la vez. El umbral 0.50 se usó solo como valor demostrativo para generar smoker_imputado; el umbral real debe fijarlo el área actuarial en función del costo monetario relativo de cada tipo de error, que no fue proporcionado en el caso.
- Costo de FP vs. FN: un falso positivo (imputar 'fumador' a quien no lo es) tiende a sobreestimar el riesgo y la prima de esa persona; un falso negativo (imputar 'no fumador' a quien sí lo es) subestima el riesgo y el costo esperado para la aseguradora. Dado que el modelo de clasificación tiene poder predictivo apenas superior al azar ($AUC \approx 0.53$), cualquier umbral elegido debe tratarse con cautela: el objetivo no es optimizar una métrica de forma aislada, sino minimizar el impacto del tipo de error más costoso para el negocio.
- Supuesto de datos faltantes: la simulación oculta etiquetas smoker de forma aleatoria (missing completely at random). En la práctica, los datos de fumador podrían faltar de forma no aleatoria (por ejemplo, si ciertos perfiles de asegurado son más propensos a no reportarlo), lo cual el experimento actual no captura ni valida.
- No uso de charges como predictor de smoker: decisión deliberada para evitar fuga de información, ya que en una aplicación real el gasto todavía no se conocería en el momento de imputar la condición de fumador.
- Selección de alpha únicamente por validación cruzada sobre entrenamiento (nunca sobre prueba), y separación de datos de prueba antes de cualquier ajuste, para obtener una estimación no sesgada del desempeño final.

6. Limitaciones

- El poder predictivo del modelo de clasificación para recuperar smoker es muy bajo (ROC-AUC $\approx$ 0.53 en validación y 0.56 sobre los registros ocultos), por lo que sus imputaciones no deben tratarse como un dato observado: deben marcarse explícitamente y revisarse antes de usarse en decisiones de precio o cobertura.
- El dataset es pequeño (1338 filas) y no tiene dimensión temporal, por lo que no es posible evaluar si el modelo generalizaría a otra población, otra región o distinta época.
- Las asociaciones encontradas (p. ej., BMI_Smoker, age) no implican relaciones causales; son señales estadísticas dentro de la muestra disponible.
- La brecha entre RMSE y MAE en el modelo de regresión refleja la presencia de gastos extremos reales (139 casos por la regla IQR); el modelo tiende a cometer errores más grandes precisamente en los asegurados de mayor costo, que son los más relevantes para el negocio.
- La ganancia del modelo Polinomios + Ridge sobre el baseline lineal es pequeña; con una muestra distinta el ordenamiento entre ambos modelos podría no sostenerse.

7. Conclusiones y recomendaciones

El modelo Polinomios grado 2 + Ridge obtiene el menor error absoluto medio de prueba (MAE = 2,689.80, $R^2 = 0.8642$) para predecir charges, aunque su ventaja sobre la regresión lineal simple es modesta. El modelo de regresión logística para imputar smoker tiene desempeño apenas superior al azar (ROC-AUC $\approx$ 0.53), lo que limita su uso como fuente confiable de ese dato.

- Usar la estimación de charges como apoyo actuarial, no como decisión automática de cobertura o precio.
- Definir con el área actuarial el costo monetario de falsos positivos y falsos negativos antes de fijar un umbral de imputación operativo para smoker.
- Marcar cada valor de smoker imputado junto con su probabilidad asociada, para que quede sujeto a revisión y no se presente como dato observado.
- Monitorear MAE y RMSE por segmentos (región, rango etario) y a lo largo del tiempo antes de desplegar el modelo de regresión en producción.
- Explorar variables adicionales o fuentes de datos complementarias para mejorar la recuperación de smoker, dado el bajo poder predictivo obtenido con las variables demográficas disponibles.