


Caso 7: Medical Cost Predictions



- Mauricio Orlando Rivera Mayan
- Rodrigo Gabriel Rivera Mayan
- Laura Yackelin Perez Estrada

Contexto del problema

Una aseguradora necesita estimar los gastos médicos anuales de sus clientes para mejorar la evaluación del riesgo.



El proyecto aborda **dos** problemas:

- Predecir el valor de charges.
- Recuperar la condición smoker cuando este dato se encuentre ausente.

Rol simulado: Actuario/a de datos junior.

Medical Cost Personal Dataset

1338 registros



7 variables



No hay valores nulos & hay
una fila duplicada



Variables



- ❑ age
- ❑ sex
- ❑ bmi
- ❑ children
- ❑ smoker
- ❑ region
- ❑ charges

insurance.csv (55.63 kB)						
Detail Compact Column						
About this file						
This dataset consists of 1338 rows.						
# age Edad del asegurado	▲ sex Género	# bmi Índice de masa corporal	# children Número de hijos	✓ smoker Indicador si fuma	▲ region Región donde vive el asegurado	# charges Prima del seguro
 18 64	male 51% female 49%	 16 53.1	 0 5	true 0 0% false 0 0%	southeast 27% southwest 24% Other (649) 49%	 1.12k 63.8k

Hallazgos

Exploración de datos

01

Distribucion

Charges presenta una distribución asimétrica hacia valores altos.

02

Valores Extremos

Se identificaron 139 posibles valores extremos mediante la regla IQR pero se conservaron porque pueden representar gastos médicos reales.

03



Fumadores

Los fumadores muestran gastos considerablemente mayores.

04

Relaciones

La edad y el IMC presentan relaciones visibles con los gastos.





Preparación de datos

Se utilizó **ColumnTransformer** junto con **Pipeline** para mantener el mismo procesamiento durante entrenamiento y evaluación.

Transformaciones:

- Imputación por mediana para variables numéricas.
- Estandarización mediante **StandardScaler**.
- Imputación por moda para variables categóricas.
- **OneHotEncoder** para region.
- Mapeo explícito de variables binarias.

- sex: female → 0, male → 1.
- smoker: no → 0, yes → 1.
- BMI_Smoker = bmi × smoker.

```
preprocesador_reg = ColumnTransformer(  
    transformers=[  
        ("num", Pipeline([  
            ("imputer", SimpleImputer(strategy="median")),  
            ("scaler", StandardScaler()),  
        ]), columnas_numericas_reg),  
        ("bin", SimpleImputer(strategy="most_frequent"), columnas_binarias_reg),  
        ("cat", Pipeline([  
            ("imputer", SimpleImputer(strategy="most_frequent")),  
            ("onehot", OneHotEncoder(handle_unknown="ignore", sparse_output=False)),  
        ]), columnas_categoricas_reg),  
    ],  
    verbose_feature_names_out=False,  
)
```

Diagnóstico del modelo

Las métricas empleadas fueron:

- **MAE:** error promedio en las unidades de charges.
- **RMSE:** penaliza con mayor fuerza los errores grandes.
- **R²:** mide la variabilidad explicada por el modelo.

El modelo con polinomios y Ridge alcanzó:

- **MAE:** 2,689.80
- **R²:** 0.8642

Aproximadamente **86.42%** de la variabilidad explicada.

Los errores mayores se relacionan con la asimetría y los gastos médicos elevados.

Comparación de modelos de regresión



Se evaluaron los dos modelos indicados en la guía:

- **Modelo baseline**
 - Regresión lineal.
- **Modelo mejorado**
 - PolynomialFeatures(degree=2).
 - Regularización Ridge.
 - Selección de alpha mediante validación cruzada.


El mejor parámetro encontrado para Ridge fue:

```
... Mejor alpha: 1.0  
MAE promedio de CV: 2968.4
```

Interpretación: Ridge obtuvo el menor MAE, aunque los dos modelos alcanzaron resultados muy similares en RMSE y R^2 .

	MAE	RMSE	R2
modelo			
Regresión lineal	2,756.90	4,573.81	0.8653
Polinomios grado 2 + Ridge	2,689.80	4,591.33	0.8642

Comparación de modelos de regresión



Imputación del smoker - Recuperación de la variable smoker



El dataset original no contiene valores nulos. Para cumplir la consigna:

- Se ocultó el 20% de smoker.
- Se utilizó la semilla 42.
- Se entrenó una regresión logística.
- Se excluyó charges para evitar fuga de información.
- Se evaluó mediante ROC-AUC y matriz de confusión.

ROC-AUC validación: 0.5267				
	precision	recall	f1-score	support
no	0.82	0.59	0.68	214
yes	0.23	0.48	0.31	54
accuracy			0.57	268
macro avg	0.52	0.54	0.50	268
weighted avg	0.70	0.57	0.61	268

Este valor está cerca de 0.50, por lo que las variables disponibles tienen poca capacidad para recuperar de forma confiable la condición de fumador.

Imputación del smoker - Recuperación de la variable smoker



Conclusión y recomendaciones

Conclusiones

- Polinomios + Ridge obtuvo el menor MAE: 2,689.80.
- Los dos modelos de regresión consiguieron un R^2 cercano a 0.864.
- La interacción BMI_Smoker permitió representar el efecto combinado exigido.
- La imputación de smoker presentó un desempeño débil.
- Un valor imputado debe identificarse como estimado y no como observado.

Recomendaciones

- Utilizar la predicción como apoyo actuarial.
- Revisar manualmente casos con gastos estimados muy altos.
- Definir el costo de falsos positivos y falsos negativos antes de seleccionar el umbral de clasificación.
- No usar la imputación de smoker para decisiones automáticas.
- Validar el modelo con información de otros periodos y poblaciones.

